

Universidad de Buenos Aires
Facultad de Ciencias Exactas y Naturales
Departamento de Computación

Materia: Temas de Procesamiento del Lenguaje Natural - NLP Aplicado

Trabajo práctico

Objetivo

El objetivo de este trabajo práctico es familiarizarse con tareas de traducción automática (Machine Translation, MT), evaluación humana de traducciones, acuerdo entre anotadores (Inter-Annotator Agreement, IAA) y métricas automáticas de evaluación de traducción.

Los estudiantes trabajarán con datos del corpus ***QomL'aqtaqa***, un corpus paralelo qom–español desarrollado para investigación en procesamiento del lenguaje natural (NLP) para lenguas de bajos recursos computacionales.

Introducción

El qom (también conocido como toba) es una lengua indígena de la familia Guaycurú hablada por aproximadamente 80.000 personas en Argentina, principalmente en la región del Gran Chaco y en algunos grandes centros urbanos del país.

Desde el punto de vista computacional, el qom es una lengua con recursos limitados. Existen pocos recursos digitales y lingüísticos disponibles para el desarrollo de tecnologías del lenguaje [3]. Además, presenta características que introducen desafíos adicionales para el procesamiento automático [17,18]:

- Variación ortográfica entre comunidades y materiales escritos.
- Complejidad morfológica elevada.
- Diferencias sintácticas importantes respecto del español.
- Escasez de corpus paralelos adecuados para tareas de traducción automática.

Recientemente se desarrolló *QomL'aqtaqa*, el primer corpus paralelo qom–español en un formato computacionalmente utilizable para investigación en traducción automática y otras tareas de NLP [4] .

La traducción automática busca construir sistemas capaces de traducir texto entre diferentes idiomas. Los sistemas modernos están basados principalmente en redes neuronales profundas entrenadas sobre grandes cantidades de texto paralelo.

La evaluación de sistemas de traducción automática constituye un problema abierto de investigación [5]. Existen tanto métodos automáticos (por ejemplo BLEU, chrF, COMET y otros) [6-10] como evaluaciones humanas realizadas por hablantes o expertos lingüísticos [13-16].

Datos

Se proveerá un conjunto de segmentos en qom junto con:

- una traducción de referencia al español (i.e. una traducción validada, el gold standard);
- una traducción al español generada automáticamente por un sistema de MT.

Los segmentos pueden corresponder a:

- oraciones completas;
- fragmentos de oraciones;
- párrafos cortos.

Tareas

1. **Evaluación humana de traducciones.** Cada integrante del grupo deberá evaluar 15 traducciones automáticas qom → español (las mismas para cada integrante). Esto constituye el **conjunto A**. Para cada traducción deberán asignar una de las siguientes categorías:
 - Correcta
 - Parcialmente correcta
 - Incorrecta

Además podrán agregar comentarios opcionales justificando la decisión o señalando dificultades encontradas durante la evaluación.

2. **Acuerdo entre anotadores.** Calcular el acuerdo entre anotadores (IAA) mediante el **Alpha de Krippendorff para datos ordinales**. Complementariamente, reportar la proporción de ejemplos con acuerdo unánime (3/3), acuerdo mayoritario (2/3) y desacuerdo completo. Analizar posteriormente:
 - cuáles fueron los casos con mayor desacuerdo;
 - cuáles fueron las principales dificultades encontradas durante la tarea de anotación;
 - qué tipos de errores generaron diferencias entre evaluadores.
 - reportar matriz de confusión entre anotadores.
3. **Diseño de criterios de evaluación.** A partir de la lectura de bibliografía relevante (ver abajo) , de la experiencia obtenida durante la anotación, **y de los ejemplos del conjunto A**, definir **y documentar** un conjunto de criterios que ustedes consideran que

deberían utilizarse para verificar la calidad de traducciones automáticas qom → español, considerando los desafíos de las lenguas de bajos recursos computacionales..

El diseño del esquema de evaluación debe estar inspirado en enfoques de evaluación humana de traducción automática, en particular en marcos estructurados como **MQM [13]**, que proponen la descomposición de la calidad en categorías de error, y puede complementarse con enfoques de evaluación directa como **Direct Assessment [14]**. También puede consultarse la implementación de evaluación de traducción automática presentada por Freitag et al. [15]. Se recomienda priorizar la simplicidad. Una guía breve y consistente posiblemente sea más adecuada que una guía más compleja pero difícil de aplicar.

Deben:

- considerarse como máximo 2 o 3 dimensiones (categorías de error en MQM, como por ej. *Fluency* -fluidez o naturalidad-),
 - Considerar que la anotación debe poder hacerse rápidamente.
 - armar una escala cerrada para cada dimensión (por ej: 1-5 y definir claramente cada nivel),
 - Proveer un ejemplo anotado.
 - Probar el criterio con el **conjunto B, de aproximadamente 10–15 traducciones, que les proveeremos**. Evalúen cuán fácil resulta aplicarlo e identifiquen posibles ambigüedades o dificultades. A partir de esta experiencia, y de corresponder, refinan el criterio. En el informe describan las dificultades encontradas y las modificaciones introducidas. Una vez estabilizada la versión final del criterio, reporten el tiempo requerido **por cada anotador** para anotar el conjunto B utilizando dicha versión final. **Entreguen el conjunto B anotado**.
 - Siendo uds el grupo n, envíenle los criterios al grupo n+1 (o el grupo 1, si corresponde).
4. **Evaluación de traducción.** El grupo n+1 (o 1) deberá evaluar traducciones de acuerdo al criterio enviado por el grupo n. Cada integrante del grupo deberá evaluar el conjunto C, que consta de 50 traducciones automáticas qom → español **por traductor**. **De estos 50 segmentos, 15 deberán ser evaluados por todos los integrantes del grupo** (informaremos qué tiene que anotar cada anotador) para permitir el cálculo de acuerdo entre anotadores. Calcular Alpha de Krippendorff utilizando el nivel de medición apropiado para la escala definida (ordinal o nominal, según corresponda) **para aquellos segmentos anotados por los 2 o 3 anotadores**. Discutir los puntos solicitados en el punto 2. Cada integrante **debe tomar nota** de cuánto tiempo le llevó anotar los 50 segmentos. **Re anotar** (en otra hoja) las traducciones de A, ahora teniendo en cuenta el propio criterio de anotación. Calcular Alpha de Krippendorff y compararlo con el calculado para el conjunto A sin tener el criterio de anotación.

5. **Métricas automáticas.** Seleccionar dos métricas automáticas de evaluación de modelos de traducción:

- una de las siguientes métricas: BLEU, chrF o chrF++ y
- una de las siguientes métricas: COMET, BERTScore. COMET requiere la descarga de modelos preentrenados y puede demandar recursos computacionales adicionales.

Para cada métrica:

- Explicar brevemente cómo funciona.
 - Justificar por qué fue seleccionada.
 - Calcularla sobre los datos provistos en el **conjunto C**.
 - Analizar sus ventajas y limitaciones para una lengua de bajos recursos como el qom. Para ello tener en cuenta el artículo del shared task de Americas NLP [12].
6. **Comparación entre evaluación humana y automática.** Comparar para el conjunto C los resultados obtenidos mediante
- evaluación humana
 - métricas automáticas elegidas.

Discutir:

1. ¿Las métricas reflejan adecuadamente la calidad percibida por los evaluadores?
 2. ¿Qué tipos de errores parecen capturar mejor?
 3. ¿Qué tipos de errores parecen ignorar?
 4. Las métricas que ustedes implementaron correlacionan con el juicio humano? Justifiquen. ¿Por qué creen que es así?
 5. ¿Consideran que una persona monolingüe en español puede evaluar correctamente la calidad de una traducción Qom→Español? ¿Qué información adicional necesitaría? ¿Qué conocimientos debería poseer una persona encargada de evaluar traducciones? ¿Qué limitaciones creen que tiene una evaluación realizada únicamente por hablantes de español?
 6. Identifiquen 2 o 3 ejemplos del conjunto A que hayan generado desacuerdo o dificultades durante la evaluación inicial. Describan brevemente cuáles fueron los problemas observados y expliquen si la guía de anotación propuesta los aborda y/o reduce su ambigüedad.
7. **Armar un informe**, estilo paper, de entre no más de 6 hojas (sin contar bibliografía ni apéndices), contando los experimentos realizados y los data statements. Se sugiere template de ACL. Debe incluir
- Introducción
 - Cuál es el problema, Por qué es importante, qué hicieron, en qué se diferencia de trabajos previos.
 - Metodología
 - Procedimiento de anotación. (en 1 y 4)

- Diseño y refinamiento de la guía de anotación (en 3), incluyendo los criterios utilizados para decidir qué aspectos evaluar
- Métricas seleccionadas (en 5), justificación, explicación de las mismas, comentarios breves sobre implementación.
- Data Statements [1,2] escritos por ustedes sobre los puntos 3 y 4. Tienen que dar cuenta de cómo está constituido el equipo que hizo la anotación y los criterios de anotación (para ellos, deberán conseguir los datos de quiénes construyeron el criterio de anotación).
- Detalles técnicos (decisiones de implementación, por ej. cómo se resuelven discrepancias entre distintas evaluaciones hechas por distintos anotadores) y cómo implementaron el IAA.
- Resultados:
 - del IAA (de los puntos 2 y 4).
 - de anotaciones (puntos 1 y 4) (pueden estar en apéndice) . Adjuntar link a resultados de anotaciones hechas por uds. y agregarlas a apéndice.
 - de métricas de evaluación implementadas.
 - Comparación entre resultados de métricas y la evaluación humana.
- Discusión: Principales dificultades encontradas, Limitaciones de las métricas, Recomendaciones para futuras evaluaciones. *Considerando además que el conjunto A fue utilizado durante el proceso de elaboración y refinamiento del criterio de anotación. ¿Qué implicancias tiene esto para la interpretación de los cambios en el IAA respecto a la versión anotada sin criterio y aquella anotada con criterio? ¿El acuerdo obtenido sobre A refleja necesariamente la calidad general del criterio? ¿Por qué?*
- Conclusiones
- Referencias bibliográficas

Fecha de entrega: Lunes 29 de junio, 23:59. Envío por mail a vivianacotik@gmail.com. Con subject: TP Temas NLP 2026 - Grupo X, en donde X es el nro del grupo.

Datasets: [aquí](#)

Cronograma:

- Miércoles 17/06: release del conjunto A.
- Viernes 19/06 antes del fin de la clase: entrega de las anotaciones del conjunto A.
- Viernes 19/06: release del conjunto B.
- Martes 23/06: envío de la guía de anotación al grupo n+1 (o al grupo 1, según corresponda).

- Miércoles 24/06 hasta las 13: intercambio de la información necesaria para los Data Statements. [Completar en planilla link a los datasets A y B anotados con el propio criterio de anotación.](#)
- Miércoles 24/06: release del conjunto C.

Referencias

- [1] Bender, E.M. and Friedman, B., 2018. Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the Association for Computational Linguistics*, 6, pp.587-604.
https://direct.mit.edu/tacl/article/doi/10.1162/tacl_a_00041/43452/Data-Statements-for-Natural-Language-Processing
- [2] https://techpolicylab.uw.edu/wp-content/uploads/2021/11/Data_Statements_Printer_Guide_V2.pdf
- [3] Ticona, B., Carranza, F.M. and Cotik, V., 2025, January. Indigenous languages spoken in Argentina: a survey of NLP and speech resources. In *Proceedings of the 31st International Conference on Computational Linguistics* (pp. 8449-8461).
- [4] Cotik, V., Korablev, A., Cúneo, P. and Laciana, P. 2026. QomL'aqtaqa: A Qom–Spanish Parallel Corpus for Natural Language Processing with Machine Translation Evaluation. To appear in *Proceedings of the Sixth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)* Association for Computational Linguistics.
- [5] Ebrahimi, A., Mager, M., Rijhwani, S., Rice, E., Oncevay, A., Baltazar, C., Cortés, M., Montaña, C., Ortega, J.E., Coto-Solano, R. and Cruz, H., 2023, July. Findings of the AmericasNLP 2023 shared task on machine translation into indigenous languages. In *Proceedings of the Workshop on Natural Language Processing for Indigenous Languages of the Americas (AmericasNLP)* (pp. 206-219).
- [6] Papineni, K., Roukos, S., Ward, T. and Zhu, W.-J. (2002) 'Bleu: a Method for Automatic Evaluation of Machine Translation', *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, pp. 311–318. doi:10.3115/1073083.1073135.
- [7] Popović, M. (2015) 'chrF: character n-gram F-score for automatic MT evaluation', *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT)*, pp. 392–395. doi:10.18653/v1/W15-3049.
- [8] Popović, M. (2017) 'chrF++: words helping character n-grams', *Proceedings of the Second Conference on Machine Translation (WMT)*, pp. 612–618. doi:10.18653/v1/W17-4770.
- [9] Zhang, T., Kishore, V., Wu, F., Weinberger, K.Q. and Artzi, Y. (2019) 'BERTScore: Evaluating Text Generation with BERT', *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*.
- [10] Rei, R., Stewart, C., Farinha, A.C. and Lavie, A. (2020) 'COMET: A Neural Framework for MT Evaluation', *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 2685–2702. doi:10.18653/v1/2020.emnlp-main.213.

[11] Jurafsky, D. and Martin, J.H. (2026) 'Machine Translation', in *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. 3rd edn. draft. Stanford University and University of Colorado Boulder, Chapter 12. Available at: <https://web.stanford.edu/~jurafsky/slp3/12.pdf> (Accessed: 11 June 2026).

[12] De Gibert, O., Pugh, R., Marashian, A., Vázquez, R., Ebrahimi, A., Denisov, P., Rice, E., Gow-Smith, E., Prieto, J., Robles, M. and Manrique, R., 2025, May. Findings of the AmericasNLP 2025 shared tasks on machine translation, creation of educational material, and translation metrics for indigenous languages of the Americas. In *Proceedings of the Fifth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)* (pp. 134-152).

[13] Lommel, A., Burchardt, A. and Uszkoreit, H. (2014) 'Multidimensional Quality Metrics (MQM): A Framework for Declaring and Describing Translation Quality Metrics', *Proceedings of the EACL Workshop on Translation Evaluation*. [Link al paper](#)

[14] Direct assessment: Graham, Y., Baldwin, T. and Mathur, N. (2013) 'Continuous Measurement Scales in Human Evaluation of Machine Translation', *Proceedings of WMT 2013*, Association for Computational Linguistics.

[15] Freitag, M., Foster, G., Grangier, D., Ratnakar, V., Tan, Q. and Macherey, W. (2021) 'Experts, Errors, and Context: A Large-Scale Study of Human Evaluation for Machine Translation', *Transactions of the Association for Computational Linguistics*, 9, pp. 1460–1474. [Link](#)

[16] MQM usage guidelines: [Downloads – MQM \(Multidimensional Quality Metrics\)](#) , [2024_03-07-MQMFull_Master-Official.xlsx](#)

[17] [Orden de palabras. posición del objeto y estructura de la...](#)

[18] [Vista do Foco estreito e correção de expectativas | LIAMES: Línguas Indígenas Americanas](#)