

Evaluación humana y automática de traducción automática qom–español: acuerdo entre anotadores, criterios de evaluación y métricas

Juan Ignacio Catania Juan Cruz Mendoza Camila Rodríguez

Grupo 6

Universidad de Buenos Aires - FCEN

2026

Resumen

Abstract ...

1. Introducción

2. Metodología

2.1. Procedimiento de anotación

2.2. Diseño y refinamiento de la guía de anotación

2.3. Métricas seleccionadas

2.4. Data Statements

2.5. Detalles técnicos e implementación del IAA

3. Resultados

Reportamos primero el acuerdo entre anotadores (IAA), luego las métricas automáticas y, por último, su comparación con la evaluación humana. El IAA se calculó con el Alpha de Krippendorff (Krippendorff, 2018) (implementación de la librería `krippendorff` de Python). Las matrices de confusión se construyeron como matrices de coincidencia agregando los tres pares de anotadores de cada ítem. Todos los links a las anotaciones se incluyen en el Apéndice A.

3.1. Acuerdo entre anotadores

Dataset A, sin criterio definido La evaluación libre en tres niveles se trató como ordinal (Incorrecta < Parcialmente correcta < Correcta). El acuerdo fue bueno ($\alpha = 0,79$): 10 de 15 segmentos con acuerdo unánime (67 %) y 5 con acuerdo mayoritario (33 %), sin casos de desacuerdo total (Tabla 1).

El desacuerdo casi siempre ocurre entre niveles adyacentes: en la matriz de confusión (Fig. 1a) todos los pares en desacuerdo son del tipo Incorrecta/Parcialmente correcta o Parcialmente correcta/Correcta.

Dataset A, con criterio propio Al volver a anotar A con el criterio propio, el acuerdo fue total ($\alpha = 1,00$ ordinal en la etiqueta global, unanimidad en los 15 segmentos). Por dimensión (escala ordinal 1–4; Tabla 2), el acuerdo fue alto en Fidelidad ($\alpha = 0,96$) y moderado en Naturalidad (0,72) y Preservación (0,73). Respecto de la versión sin guía, α aumenta de 0,79 a 1,00. Cabe señalar que esto podría ser un sobreajuste, dado que la guía A fue usada para desarrollar el propio criterio.

Dataset B, con criterio propio Sobre un conjunto no empleado en el diseño de la guía, el acuerdo global fue alto ($\alpha = 0,84$; 12/15 unánimes). Por dimensión, Fidelidad mantiene un acuerdo elevado (0,89), mientras que Naturalidad y Preservación bajan (0,31 y 0,52).

El bajo valor de Naturalidad coincide con un acuerdo observado alto (13/15 unánimes) pero escasa varianza (puntajes casi siempre 3–4): al ser elevado el acuerdo esperado por azar, α baja.

Dataset C, con criterio externo La guía del Grupo 5 emplea dos dimensiones (Precisión y Fluidez) en una escala continua 0–20 (Direct Assessment, con cinco rangos), que tratamos como ordinal. El IAA se calculó sobre los 15 segmentos anotados por los tres evaluadores.

La Precisión muestra acuerdo alto ($\alpha = 0,93$) y la Fluidez, moderado ($\alpha = 0,73$). Para las proporciones de acuerdo y la confusión redondeamos cada puntaje al rango más cercano {0, 5, 10, 15, 20}: en Precisión, 8/15 unánimes y 7/15 mayoritarios. En Fluidez, 9/15 unánimes, 4 mayoritarios y 2 en desacuerdo total.

3.2. Métricas automáticas

Calculamos BLEU con sacreBLEU (Post, 2018; Papineni et al., 2002) y BERTScore (Zhang et al., 2019), comparando la salida automática contra la referencia en español sobre los 120 segmentos únicos del conjunto C (15 compartidos más

Matrices de confusión (coincidencia por pares de anotadores)




Figura 1: Matrices de confusión por pares de anotadores. Cada ítem aporta sus 3 pares, contabilizados de forma simétrica (un par que coincide suma 2 en la diagonal). (a) Conjunto A sin guía, etiqueta global; (b) y (c) Precisión y Fluidez del conjunto C, redondeadas a los rangos 0–20.

Conjunto (global)	Escala	α	3/3	2/3	0/3	Métrica	Nivel	Valor
A sin guía	ordinal	0,79	67 %	33 %	0 %	BLEU	corpus	28,8
A con guía	ordinal	1,00	100 %	0 %	0 %	BLEU	oración (media)	45,3
B con guía	ordinal	0,84	80 %	20 %	0 %	BLEU	oración (mediana)	37,7
C – Precisión	ordinal	0,93	53 %	47 %	0 %	BERTScore F1	oración (media)	0,656
C – Fluidez	ordinal	0,73	60 %	27 %	13 %	BERTScore Precisión	oración (media)	0,681
						BERTScore Recall	oración (media)	0,634

Tabla 1: IAA (Alpha de Krippendorff) y proporciones de acuerdo con $N = 15$ en todos los casos. En C, α se computa sobre los puntajes crudos 0–20 y las proporciones sobre los valores redondeados a los rangos.

Dimensión	A (con guía)		B	
	α	3/3	α	3/3
Fidelidad	0,96	87 %	0,89	67 %
Naturalidad	0,72	60 %	0,31	87 %
Preservación	0,73	73 %	0,52	47 %

Tabla 2: IAA por dimensión de la guía propia (escala ordinal 1–4, $N = 15$).

35 por anotador). BLEU se computa a nivel de corpus (tokenización 13a) y, para la correlación, a nivel de oración (con smoothing exponencial); BERTScore se reporta como media de los puntajes por oración (no posee variante de corpus) y se computó con el modelo multilingüe `bert-base-multilingual-cased` (`lang=es`), con reescalado oficial respecto de la línea base. La Tabla 3 indica el nivel de agregación de cada métrica.

Sin reescalado, los valores absolutos de BERTScore no son directamente interpretables: por la similitud de base entre oraciones en español, incluso pares no relacionados reciben puntajes altos. El reescalado oficial respecto de la línea base (Zhang

Tabla 3: Métricas automáticas sobre el conjunto C ($N = 120$), con el nivel de agregación de cada una. sacreBLEU 2.6.0 (13a; smoothing exp a nivel de oración); BERTScore con el modelo multilingüe (`bert-base-multilingual-cased`) y reescalado oficial respecto de la línea base (Zhang et al., 2019).

et al., 2019) corrige esto ubicando esos pares cerca de 0, y deja el F1 medio en 0,656. El valor de BLEU, por su parte, debe leerse en el contexto de bajos recursos: los resultados del shared task AmericasNLP 2025 (De Gibert et al., 2025) son el punto de comparación de referencia, que se discute en la Sección 4.

3.3. Comparación humana vs. automática

Para cada segmento de C tomamos como ground truth el promedio de los anotadores (tres en los segmentos compartidos, uno en el resto) y lo correlacionamos con cada métrica mediante el coeficiente de Pearson (r). Ambas métricas se correlacionan de forma significativa con el juicio humano y, en todos los casos, más con Precisión que con Fluidez, lo cual es esperable dado que miden similitud con la referencia (Tabla 4, Fig. 2).

BERTScore supera a BLEU frente a las tres variables humanas. El patrón se mantiene al restringir el análisis a los 15 segmentos compartidos

Métricas automáticas vs. juicio humano de Precisión (conjunto C, N=120)




Figura 2: Métricas automáticas frente al juicio humano de Precisión (conjunto C, $N = 120$). La recta es el ajuste lineal y r es el coeficiente de Pearson.

Métrica	Precisión	Fluidez	Global
BLEU (oración)	0,69	0,31	0,62
BERTScore F1 (oración)	0,78	0,45	0,74

Tabla 4: Correlación de Pearson (r) entre cada métrica (a nivel de oración) y el juicio humano ($N = 120$).

(promediados sobre tres anotadores): BERTScore–Precisión $r = 0,82$ y BLEU–Precisión $r = 0,61$, mientras que la correlación con Fluidez no resulta significativa.

3.4. Anotaciones

Las anotaciones completas de los conjuntos A (sin guía y con guía propia), B y C se encuentran en el Apéndice A (enlaces a las planillas).

4. Discusión

5. Conclusiones

Referencias

- Ona De Gibert, Robert Pugh, Ali Marashian, Raúl Vázquez, Abteen Ebrahimi, and 1 others. 2025. Findings of the AmericasNLP 2025 shared tasks on machine translation, creation of educational material, and translation metrics for indigenous languages of the americas. In *Proceedings of the Fifth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, pages 134–152.
- Klaus Krippendorff. 2018. *Content Analysis: An Introduction to Its Methodology*, 4th edition. SAGE Publications.
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. [BLEU: a method for automatic evaluation of machine translation](#). In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 311–318.

Matt Post. 2018. A call for clarity in reporting BLEU scores. In *Proceedings of the Third Conference on Machine Translation (WMT)*, pages 186–191.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2019. BERTScore: Evaluating text generation with BERT. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*.

A. Anotaciones (enlaces)

B. Tablas y material complementario