

Evaluación humana y automática de traducción automática qom–español: acuerdo entre anotadores, criterios de evaluación y métricas

Juan Ignacio Catania Juan Cruz Mendoza Camila Rodríguez

Grupo 6

Universidad de Buenos Aires - FCEN

2026

Abstract

Estudiamos cómo evaluar la calidad de un sistema de traducción automática (MT) qom–español sobre el corpus QomL’aqtaqa, una lengua indígena de bajos recursos. Tres anotadores hispanohablantes evaluamos las traducciones y medimos el acuerdo entre anotadores (IAA) con el Alpha de Krippendorff. Diseñamos una guía de anotación simple inspirada en MQM (tres dimensiones en escala 1–4 más una etiqueta global) y la comparamos con una anotación inicial sin guía: el acuerdo sobre el conjunto A sube de $\alpha = 0,79$ a $\alpha = 1,00$, aunque ese aumento debe leerse con cautela porque A se usó para construir la guía. Finalmente calculamos BLEU y BERTScore sobre el conjunto C y las comparamos con el juicio humano: ambas correlacionan de forma significativa, y BERTScore más que BLEU, sobre todo con la dimensión de precisión. Discutimos las limitaciones de evaluar una traducción qom–español únicamente con hablantes de español.

1 Introducción

La traducción automática (*Machine Translation*, MT) se ocupa de crear sistemas que traduzcan texto de un idioma a otro. Hoy en día, estos sistemas usan sobre todo redes neuronales entrenadas con muchísimo texto en varios idiomas a la vez (Jurafsky and Martin, 2026). El problema es que *evaluar* qué tan bien funcionan estos sistemas sigue siendo difícil (Ebrahimi et al., 2023), sobre todo en lenguas con pocos recursos. En estos casos faltan datos, faltan recursos lingüísticos y faltan personas que puedan juzgar si una traducción es buena o no.

El qom (también llamado toba) es una lengua indígena de la familia Guaycurú que hablan alrededor de 80.000 personas en Argentina, sobre todo en el Gran Chaco (Ticona et al., 2025). Para una computadora es una lengua difícil de trabajar: hay pocos recursos digitales, la ortografía cambia según la comunidad, la morfología es muy compleja,

la sintaxis es bastante distinta a la del español y casi no existen corpus paralelos. Hace poco se creó QomL’aqtaqa, el primer corpus paralelo qom–español en un formato que se puede usar computacionalmente (Cotik et al., 2026). Gracias a esto, por primera vez se puede estudiar de forma sistemática la calidad de la traducción automática entre estos dos idiomas.

Evaluar la MT en este contexto importa por dos motivos. Primero, las métricas automáticas más usadas (BLEU, chrF, COMET, etc.) (Papineni et al., 2002; Popović, 2015; Rei et al., 2020) se pensaron y se probaron casi siempre con lenguas que tienen muchos recursos, así que no está claro que funcionan bien en una lengua como el qom, que tiene una morfología rica y pocos recursos (De Gibert et al., 2025). Segundo, la evaluación humana, que suele tomarse como referencia, es cara, subjetiva y depende de que haya hablantes o expertos disponibles. Por eso es importante entender cuánto se ponen de acuerdo los anotadores y por qué a veces no lo hacen.

En este trabajo: (i) hicimos una evaluación humana de traducciones automáticas qom–español, poniéndole a cada segmento una categoría de calidad; (ii) medimos cuánto se pusieron de acuerdo los anotadores (*Inter-Annotator Agreement*, IAA) con el Alpha de Krippendorff y miramos los casos donde más diferían; (iii) armamos y fuimos mejorando una guía de anotación, inspirada en marcos como MQM (Lommel et al., 2014) y en la evaluación directa (Graham et al., 2013), buscando que fuera simple y rápida de usar; (iv) calculamos dos métricas automáticas y (v) comparamos los juicios humanos con esas métricas, viendo cuánto se parecen y qué tipos de errores detecta cada una.

A diferencia de otros trabajos que se enfocan en armar o evaluar sistemas de MT para lenguas indígenas usando solo métricas automáticas (Ebrahimi et al., 2023; De Gibert et al., 2025), a nosotros nos interesa el *proceso de evaluación* en sí. Com-

paramos evaluación humana y automática sobre los mismos datos, vemos cómo el diseño de la guía de anotación afecta el acuerdo entre anotadores y documentamos todo el proceso con *data statements* (Bender and Friedman, 2018).

2 Metodología

2.1 Datos

Trabajamos con datos del corpus paralelo qom-español QomL'aqtaqa (Cotik et al., 2026). Cada ítem consiste en un segmento en qom acompañado de (i) una traducción de referencia al español validada y (ii) una traducción al español generada automáticamente por un sistema de MT. Los segmentos pueden ser oraciones completas, fragmentos de oraciones o párrafos cortos. Se utilizaron tres conjuntos: el **conjunto A** (15 traducciones evaluadas por todos los integrantes), el **conjunto B** (15 traducciones, usado para probar y refinar la guía de anotación) y el **conjunto C** (50 traducciones por anotador, de las cuales 15 fueron anotadas por todos los integrantes para el cálculo de IAA).

2.2 Procedimiento de anotación

Anotación inicial (conjunto A). Cada integrante del grupo evaluó de forma independiente las 15 traducciones automáticas del conjunto A, asignando a cada una una de tres categorías de calidad: *Correcta*, *Parcialmente correcta* o *Incorrecta*. Esta escala de tres niveles se aplicó sin ningún acuerdo o guía, registrando además comentarios opcionales que justificaban la decisión o señalaban dificultades encontradas durante la evaluación. La anotación se realizó en una planilla de cálculo compartida con columnas independientes por anotador, comparando la traducción automática contra la traducción de referencia en español.

Anotación con criterio propio (conjunto B y re-anotación de A). En una segunda etapa, a partir de la lectura de MQM (Lommel et al., 2014) armamos nuestra propia guía de anotación, descrita en la Sección 2.3. Usamos esa guía para anotar el conjunto B y, además, para volver a anotar el conjunto A. De este modo el conjunto A quedó anotado dos veces: primero con las tres etiquetas sin guía y luego con nuestro criterio, lo que nos permite comparar el acuerdo entre anotadores con y sin guía. Cada anotador registró el tiempo que le insumió la anotación.

Anotación del conjunto C con criterio externo (Grupo 5). Finalmente, el conjunto C (50 segmentos por anotador) se anotó usando el criterio de anotación elaborado por el **Grupo 5**, que recibimos como parte del intercambio entre grupos. Ese criterio define dos dimensiones, *Precisión* y *Fluidez*, sobre una escala continua de 0 a 20 al estilo *Direct Assessment* (Graham et al., 2013), con anclas semánticas en los valores {0, 5, 10, 15, 20}. De los 50 segmentos, 15 fueron anotados por todos los integrantes para poder calcular el IAA. Cada anotador registró el tiempo total que le llevó anotar los 50 segmentos.

2.3 Diseño y refinamiento de la guía de anotación

Qué decidimos evaluar. Para diseñar la guía nos basamos en MQM (Lommel et al., 2014), que propone descomponer la calidad en distintas dimensiones. Buscamos algo simple y rápido de aplicar, así que elegimos tres dimensiones, cada una con una escala de 1 a 4 (4 = mejor, 1 = peor):

- **Fidelidad del significado:** ¿la traducción conserva el significado del segmento respecto de la referencia?
- **Naturalidad / Fluidez:** ¿la traducción suena natural y es gramaticalmente correcta en español, más allá de su fidelidad al original?
- **Preservación de elementos clave:** ¿se conservan nombres propios, lugares, números, fechas, cantidades y términos culturales específicos del qom?

Ajuste y anotación. Primero anotamos el conjunto B con esta guía, que en un principio solo tenía las tres dimensiones. Al hacerlo notamos que, para poder comparar después con las etiquetas (Correcta, Incorrecta, Parcialmente correcta) ya asignadas al conjunto A, nos faltaba una categoría equivalente. Por eso ajustamos la guía agregando una *etiqueta global* de tres categorías derivada de las tres dimensiones, según la siguiente regla:

- **Incorrecta:** si alguna dimensión vale 1, o bien si Fidelidad vale 2.
- **Correcta:** si las tres dimensiones valen 4.
- **Parcialmente correcta:** cualquier otro caso (hay algún 3, o algún 2 que no sea de Fidelidad).

Le dimos mayor prioridad a la Fidelidad puesto que un error de significado es más grave que uno de naturalidad: un segmento con Fidelidad baja se penaliza aunque las demás dimensiones sean altas. Con esta versión final re-anotamos el conjunto A; la etiqueta global del conjunto B se obtuvo aplicando la misma regla a las dimensiones ya puntuadas.

2.4 Métricas seleccionadas

Para evaluar el sistema de MT sobre el conjunto C usamos dos métricas: **BLEU** y **BERTScore**. Las dos comparan la traducción automática con la de referencia, pero de forma distinta: BLEU mira si coinciden las palabras y BERTScore mira si coinciden los significados. Las combinamos para tener las dos miradas. Acá explicamos cada una y por qué la elegimos; los valores obtenidos se reportan en la Sección 3.2.

BLEU. BLEU (Papineni et al., 2002) cuenta cuántas palabras y grupos de palabras (de 1 a 4) aparecen tanto en la traducción automática como en la de referencia. Cuantas más coincidan, más alto es el puntaje (de 0 a 100); además baja la nota si la traducción es demasiado corta. La elegimos porque es la métrica más usada en traducción automática, es fácil y rápida de calcular y no necesita modelos entrenados. La calculamos con sacreBLEU (Post, 2018) (tokenizador 13a).

BERTScore. BERTScore (Zhang et al., 2020) no busca palabras idénticas, sino palabras que *significan* lo mismo. Para eso usa un modelo de lenguaje (tipo BERT) que convierte cada palabra en un vector y compara qué tan parecidos son los de la traducción y los de la referencia. Así reconoce sinónimos y reformulaciones que BLEU pasa por alto. La elegimos para complementar a BLEU. Como traducimos qom→español, el texto que evaluamos está en español, así que usamos el modelo `multilingüe bert-base-multilingual-cased (lang=es)` con reescalado respecto de la línea base oficial, que hace los valores más interpretables; se promedia a nivel de oración (no tiene variante de corpus).

Ventajas y limitaciones para una lengua de bajos recursos. Algo importante de nuestro trabajo es que la traducción va de qom a español, así que las métricas trabajan sobre el *español*, no sobre el qom. Esto es una ventaja frente al caso contrario que estudia AmericasNLP (De Gibert et al., 2025), donde el texto a evaluar está en la lengua

indígena y faltan modelos y herramientas. Aun así, hay límites: (i) las métricas no miran el qom original, solo comparan el español generado con una única referencia, así que no se dan cuenta si se perdió o cambió el sentido del texto de partida; una traducción que suena bien pero dice otra cosa puede igual sacar buena nota. (ii) BLEU castiga cuando se usan otras palabras válidas (sinónimos, otro orden, otra conjugación); por eso en lenguas de bajos recursos se suele preferir chrF (Popović, 2015). BERTScore tolera mejor esto, pero depende de qué tan bueno sea el modelo que usa. (iii) el conjunto de evaluación es chico y tiene una sola referencia, así que los puntajes son poco estables. Por eso tomamos estas métricas como una pista aproximada y las comparamos con la evaluación humana.

2.5 Data Statements

Documentamos quiénes hicimos la anotación, ya que nuestro perfil influye en los juicios de calidad. Somos tres estudiantes argentinos de Ciencia de Datos, de alrededor de 22 años, hablantes nativos de español y sin conocimiento de qom, con poca experiencia previa en anotación. Los tres anotamos todos los conjuntos. Una consecuencia directa es que no pudimos juzgar la fidelidad contra el qom de origen, sino solo contra la traducción de referencia en español.

El criterio usado para anotar el conjunto C fue elaborado por el Grupo 5.

2.6 Detalles técnicos e implementación del IAA

Para medir el acuerdo entre anotadores usamos el Alpha de Krippendorff (Krippendorff, 2018), apropiado cuando hay varios anotadores y una escala ordinal, mediante la librería `krippendorff` de Python. Lo calculamos sobre la etiqueta global de tres categorías y sobre cada dimensión de la guía, además del conjunto C con la escala del Grupo 5. Complementariamente reportamos cuántos segmentos tuvieron acuerdo total (3/3), acuerdo de la mayoría (2/3) o desacuerdo completo, junto con la matriz de confusión entre anotadores. No unificamos las anotaciones en una sola etiqueta: las diferencias se reportan tal cual, ya que son justamente lo que nos interesa analizar.

3 Resultados

Reportamos primero el acuerdo entre anotadores (IAA), luego las métricas automáticas y, por úl-

timo, su comparación con la evaluación humana. El IAA se calculó con el Alpha de Krippendorff (Krippendorff, 2018) (implementación de la librería `krippendorff` de Python). Las matrices de confusión se construyeron como matrices de coincidencia agregando los tres pares de anotadores de cada ítem. Todos los links a las anotaciones se incluyen en el Apéndice A.

3.1 Acuerdo entre anotadores

Dataset A, sin criterio definido La evaluación libre en tres niveles se trató como ordinal (Incorrecta < Parcialmente correcta < Correcta). El acuerdo fue bueno ($\alpha = 0,79$): 10 de 15 segmentos con acuerdo unánime (67%) y 5 con acuerdo mayoritario (33%), sin casos de desacuerdo total (Tabla 1).

El desacuerdo casi siempre ocurre entre niveles adyacentes: en la matriz de confusión (Fig. 1a) todos los pares en desacuerdo son del tipo Incorrecta/Parcialmente correcta o Parcialmente correcta/Correcta.

Dataset A, con criterio propio Al volver a anotar A con el criterio propio, el acuerdo fue total ($\alpha = 1,00$ ordinal en la etiqueta global, unanimidad en los 15 segmentos). Por dimensión (escala ordinal 1–4; Tabla 2), el acuerdo fue alto en Fidelidad ($\alpha = 0,96$) y moderado en Naturalidad (0,72) y Preservación (0,73). Respecto de la versión sin guía, α aumenta de 0,79 a 1,00. Cabe señalar que esto podría ser un sobreajuste, dado que la guía A fue usada para desarrollar el propio criterio.

Dataset B, con criterio propio Sobre un conjunto no empleado en el diseño de la guía, el acuerdo global fue alto ($\alpha = 0,84$; 12/15 unánimes). Por dimensión, Fidelidad mantiene un acuerdo elevado (0,89), mientras que Naturalidad y Preservación bajan (0,31 y 0,52).

El bajo valor de Naturalidad coincide con un acuerdo observado alto (13/15 unánimes) pero escasa varianza (puntuajes casi siempre 3–4): al ser elevado el acuerdo esperado por azar, α baja.

Dataset C, con criterio externo La guía del Grupo 5 emplea dos dimensiones (Precisión y Fluidez) en una escala continua 0–20 (Direct Assessment, con cinco rangos), que tratamos como ordinal. El IAA se calculó sobre los 15 segmentos anotados por los tres evaluadores.

La Precisión muestra acuerdo alto ($\alpha = 0,93$) y la Fluidez, moderado ($\alpha = 0,73$). Para las propor-

Conjunto (global)	Escala	α	3/3	2/3	0/3
A sin guía	ordinal	0,79	67%	33%	0%
A con guía	ordinal	1,00	100%	0%	0%
B con guía	ordinal	0,84	80%	20%	0%
C – Precisión	ordinal	0,93	53%	47%	0%
C – Fluidez	ordinal	0,73	60%	27%	13%

Tabla 1: IAA (Alpha de Krippendorff) y proporciones de acuerdo con $N = 15$ en todos los casos. En C, α se computa sobre los puntajes crudos 0–20 y las proporciones sobre los valores redondeados a los rangos.

Dimensión	A (con guía)		B	
	α	3/3	α	3/3
Fidelidad	0,96	87%	0,89	67%
Naturalidad	0,72	60%	0,31	87%
Preservación	0,73	73%	0,52	47%

Tabla 2: IAA por dimensión de la guía propia (escala ordinal 1–4, $N = 15$).

ciones de acuerdo y la confusión redondeamos cada puntaje al rango más cercano $\{0, 5, 10, 15, 20\}$: en Precisión, 8/15 unánimes y 7/15 mayoritarios. En Fluidez, 9/15 unánimes, 4 mayoritarios y 2 en desacuerdo total.

3.2 Métricas automáticas

Calculamos BLEU con `sacreBLEU` (Post, 2018; Papineni et al., 2002) y BERTScore (Zhang et al., 2020), comparando la salida automática contra la referencia en español sobre los 120 segmentos únicos del conjunto C (15 compartidos más 35 por anotador). BLEU se computa a nivel de corpus (tokenización 13a) y, para la correlación, a nivel de oración (con smoothing exponencial); BERTScore se reporta como media de los puntajes por oración (no posee variante de corpus) y se computó con el modelo `multilingüe bert-base-multilingual-cased (lang=es)`, con reescalado oficial respecto de la línea base. La Tabla 3 indica el nivel de agregación de cada métrica.

Sin reescalado, los valores absolutos de BERTScore no son directamente interpretables: por la similitud de base entre oraciones en español, incluso pares no relacionados reciben puntajes altos. El reescalado oficial respecto de la línea base (Zhang et al., 2020) corrige esto ubicando esos pares cerca de 0, y deja el F1 en 0,656.

El valor de BLEU debe leerse en el contexto de bajos recursos: como referencia de literatura, en el shared task AmericasNLP 2025 (De Gibert

Matrices de confusión (coincidencia por pares de anotadores)




Figura 1: Matrices de confusión por pares de anotadores. Cada ítem aporta sus 3 pares, contabilizados de forma simétrica (un par que coincide suma 2 en la diagonal). (a) Conjunto A sin guía, etiqueta global; (b) y (c) Precisión y Fluidez del conjunto C, redondeadas a los rangos 0–20.

Métrica	Nivel	Valor
BLEU	corpus	28,8
BLEU	oración (media)	45,3
BLEU	oración (mediana)	37,7
BERTScore F1	oración (media)	0,656
BERTScore Precisión	oración (media)	0,681
BERTScore Recall	oración (media)	0,634

Tabla 3: Métricas automáticas sobre el conjunto C ($N = 120$), con el nivel de agregación de cada una. sacreBLEU 2.6.0 (13a; smoothing exp a nivel de oración); BERTScore con el modelo multilingüe (bert-base-multilingual-cased) y reescalado oficial respecto de la línea base (Zhang et al., 2020).

et al., 2025) el mejor sistema de traducción hacia el español promedia BLEU $\approx 7,2$ sobre 13 lenguas indígenas (allí la métrica principal es chrF++). El qom no integra ese conjunto y los segmentos de C son breves, por lo que la comparación es solo orientativa: el BLEU de 28,8 refleja en buena medida esa diferencia de tarea (lengua, dirección y longitud de los segmentos) más que necesariamente un sistema superior.

3.3 Comparación humana vs. automática

Para cada segmento de C tomamos como ground truth el promedio de los anotadores (tres en los segmentos compartidos, uno en el resto) y lo correlacionamos con cada métrica mediante el coeficiente de Pearson (r). Ambas métricas se correlacionan de forma significativa con el juicio humano y, en todos los casos, más con Precisión que con Fluidez, lo cual es esperable dado que miden similitud con la referencia (Tabla 4, Fig. 2).

BERTScore supera a BLEU frente a las tres

Métrica	Precisión	Fluidez	Global
BLEU (oración)	0,69	0,31	0,62
BERTScore F1 (oración)	0,78	0,45	0,74

Tabla 4: Correlación de Pearson (r) entre cada métrica (a nivel de oración) y el juicio humano ($N = 120$).

variables humanas. El patrón se mantiene al restringir el análisis a los 15 segmentos compartidos (promediados sobre tres anotadores): BERTScore–Precisión $r = 0,82$ y BLEU–Precisión $r = 0,61$, mientras que la correlación con Fluidez no resulta significativa.

4 Discusión

5 Conclusiones

Referencias

- Emily M. Bender and Batya Friedman. 2018. Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the Association for Computational Linguistics*, 6:587–604.
- Viviana Cotik, A. Korablev, P. Cúneo, and P. Laciana. 2026. QomL’aqtaqa: A qom–spanish parallel corpus for natural language processing with machine translation evaluation. In *Proceedings of the Sixth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*. To appear.
- Ona De Gibert, Robert Pugh, Ali Marashian, Raúl Vázquez, Abteen Ebrahimi, and 1 others. 2025. Findings of the AmericasNLP 2025 shared tasks on machine translation, creation of educational material, and translation metrics for indigenous languages of the americas. In *Proceedings of the Fifth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, pages 134–152.

Métricas automáticas vs. juicio humano de Precisión (conjunto C, N=120)




Figura 2: Métricas automáticas frente al juicio humano de Precisión (conjunto C, $N = 120$). La recta es el ajuste lineal y r es el coeficiente de Pearson.

Abteen Ebrahimi, Manuel Mager, Shruti Rijhwani, Enora Rice, Arturo Oncevay, and 1 others. 2023. Findings of the AmericasNLP 2023 shared task on machine translation into indigenous languages. In *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, pages 206–219.

Yvette Graham, Timothy Baldwin, and Nitika Mathur. 2013. Continuous measurement scales in human evaluation of machine translation. In *Proceedings of WMT 2013*.

Daniel Jurafsky and James H. Martin. 2026. Machine translation. Speech and Language Processing, 3rd ed. draft, Chapter 12. <https://web.stanford.edu/~jurafsky/slp3/12.pdf>.

Klaus Krippendorff. 2018. *Content Analysis: An Introduction to Its Methodology*, 4th edition. SAGE Publications.

Arle Lommel, Aljoscha Burchardt, and Hans Uszkoreit. 2014. Multidimensional quality metrics (MQM): A framework for declaring and describing translation quality metrics. In *Proceedings of the EACL Workshop on Translation Evaluation*.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. [BLEU: a method for automatic evaluation of machine translation](#). In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 311–318.

Maja Popović. 2015. chrF: character n-gram f-score for automatic MT evaluation. In *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT)*, pages 392–395.

Matt Post. 2018. A call for clarity in reporting BLEU scores. In *Proceedings of the Third Conference on Machine Translation (WMT)*, pages 186–191.

Ricardo Rei, Craig Stewart, Ana C. Farinha, and Alon Lavie. 2020. COMET: A neural framework for MT

evaluation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2685–2702.

B. Ticona, F. M. Carranza, and V. Cotik. 2025. Indigenous languages spoken in argentina: a survey of NLP and speech resources. In *Proceedings of the 31st International Conference on Computational Linguistics*, pages 8449–8461.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2020. BERTScore: Evaluating text generation with BERT. In *Proceedings of the 8th International Conference on Learning Representations (ICLR)*.

A Anotaciones (enlaces)

Las planillas con las anotaciones completas están disponibles en los siguientes enlaces:

- **Conjunto A** (sin criterio): [enlace](#).
- **Conjunto A** (con criterio propio): [enlace](#).
- **Conjunto B** (criterio propio): [enlace](#).
- **Conjunto C** (criterio externo): [enlace](#).

B Tablas y material complementario