

Evaluación humana y automática de traducción automática qom–español: acuerdo entre anotadores, criterios de evaluación y métricas

Juan Ignacio Catania Juan Cruz Mendoza Camila Rodríguez

Grupo 6

Universidad de Buenos Aires - FCEN

2026

Abstract

Estudiamos cómo evaluar la calidad de un sistema de traducción automática (MT) de qom (una lengua indígena de bajos recursos) a español sobre el corpus QomL’aqtaqa. Tres anotadores hispanohablantes evaluamos las traducciones y medimos el acuerdo entre anotadores (IAA) con el Alpha de Krippendorff. Diseñamos una guía de anotación simple inspirada en MQM (tres dimensiones en escala 1–4 más una etiqueta global) y la comparamos con una anotación inicial sin guía: el acuerdo sobre el dataset A sube de $\alpha = 0,79$ a $\alpha = 1,00$ (como también aumenta en datos nuevos). Finalmente calculamos BLEU y BERTScore sobre el dataset C y las comparamos con el juicio humano: ambas correlacionan de forma significativa, y BERTScore más que BLEU, sobre todo con la dimensión de precisión. Discutimos las limitaciones de evaluar una traducción qom–español únicamente con hablantes de español.

1 Introducción

La traducción automática (*Machine Translation*, MT) se ocupa de crear sistemas que traduzcan texto de un idioma a otro. Hoy en día, estos sistemas usan sobre todo redes neuronales entrenadas con muchísimo texto en varios idiomas a la vez (Jurafsky and Martin, 2026). El problema es que *evaluar* qué tan bien funcionan estos sistemas sigue siendo difícil (Ebrahimi et al., 2023), sobre todo en lenguas con pocos recursos. En estos casos faltan datos, recursos lingüísticos y personas que puedan juzgar si una traducción es buena o no.

El qom (también llamado toba) es una lengua indígena de la familia Guaycurú que hablan alrededor de 80.000 personas en Argentina, sobre todo en el Gran Chaco (Ticona et al., 2025). Para una computadora es una lengua difícil de trabajar: hay pocos recursos digitales, la ortografía cambia según la comunidad, la morfología es muy compleja, la sintaxis es bastante distinta a la del español y

casi no existen corpus paralelos. Hace poco se creó QomL’aqtaqa, el primer corpus paralelo qom–español en un formato que se puede usar computacionalmente (Cotik et al., 2026). Gracias a esto, por primera vez se puede estudiar de forma sistemática la calidad de la traducción automática entre estos dos idiomas.

Evaluar la MT en este contexto importa por dos motivos. Primero, las métricas automáticas más usadas (BLEU, chrF, COMET, etc.) (Papineni et al., 2002; Popović, 2015; Rei et al., 2020) se pensaron y se probaron casi siempre con lenguas que tienen muchos recursos, así que no está claro que funcionan bien en una lengua como el qom, que tiene una morfología rica y pocos recursos (De Gibert et al., 2025). Segundo, la evaluación humana, que suele tomarse como referencia, es cara, subjetiva y depende de que haya hablantes o expertos disponibles. Por eso es importante entender cuánto se ponen de acuerdo los anotadores y por qué a veces no lo hacen.

En este trabajo: (i) hicimos una evaluación humana de traducciones automáticas qom–español, poniéndole a cada segmento una categoría de calidad; (ii) medimos cuánto se pusieron de acuerdo los anotadores (*Inter-Annotator Agreement*, IAA) con el Alpha de Krippendorff y miramos los casos donde más diferían; (iii) armamos y fuimos mejorando una guía de anotación, inspirada en marcos como MQM (Lommel et al., 2014) y en la evaluación directa (Graham et al., 2013), buscando que fuera simple y rápida de usar; (iv) calculamos dos métricas automáticas y (v) comparamos los juicios humanos con esas métricas, viendo cuánto se parecen y qué tipos de errores detecta cada una.

A diferencia de otros trabajos que se enfocan en armar o evaluar sistemas de MT para lenguas indígenas usando solo métricas automáticas (Ebrahimi et al., 2023; De Gibert et al., 2025), a nosotros nos interesa el proceso de evaluación en sí. Comparamos evaluación humana y automática sobre los

misimos datos, vemos cómo el diseño de la guía de anotación afecta el acuerdo entre anotadores y documentamos todo el proceso con *data statements* (Bender and Friedman, 2018).

2 Metodología

2.1 Datos

Cada ítem del corpus QomL’aqtaqa consiste en un segmento en qom acompañado de (i) una traducción de referencia al español validada y (ii) una traducción al español generada automáticamente por un sistema de MT. Los segmentos pueden ser oraciones completas, fragmentos de oraciones o párrafos cortos. Se utilizaron tres datasets: el **dataset A** (15 traducciones evaluadas por todos los integrantes), el **dataset B** (15 traducciones, usado para probar y refinar la guía de anotación) y el **dataset C** (50 traducciones por anotador, de las cuales 15 fueron anotadas por todos los integrantes para el cálculo de IAA).

2.2 Procedimiento de anotación

Anotación inicial (dataset A). Cada integrante del grupo evaluó de forma independiente las 15 traducciones automáticas del dataset A, asignando a cada una una de tres categorías de calidad: *Correcta*, *Parcialmente correcta* o *Incorrecta*. Esta escala de tres niveles se aplicó sin ninguna guía común, comparando la traducción automática contra la traducción de referencia en español.

Anotación con criterio propio (dataset B y re-anotación de A). En una segunda etapa, a partir de la lectura de MQM (Lommel et al., 2014) armamos nuestra propia guía de anotación, descrita en la Sección 2.3. Usamos esa guía para anotar el dataset B y, además, para volver a anotar el dataset A. De este modo el dataset A quedó anotado dos veces, lo que nos permite comparar el acuerdo entre anotadores con y sin guía.

Anotación del dataset C con criterio externo (Grupo 5). Finalmente, el dataset C (50 segmentos por anotador) se anotó usando el criterio de anotación elaborado por el **Grupo 5**, que recibimos como parte del intercambio entre grupos. Ese criterio define dos dimensiones, *Precisión* y *Fluidez*, sobre una escala continua de 0 a 20 al estilo *Direct Assessment* (Graham et al., 2013), con rangos en los valores {0, 5, 10, 15, 20} que tratamos como ordinal. De los 50 segmentos, 15 fueron anotados por todos los integrantes para poder calcular

el IAA. Cada anotador registró el tiempo total que le llevó anotar los 50 segmentos.

2.3 Diseño y refinamiento de la guía de anotación

Qué decidimos evaluar. Para diseñar la guía nos basamos en MQM (Lommel et al., 2014), que propone descomponer la calidad en distintas dimensiones. Buscamos algo simple y rápido de aplicar, así que elegimos tres dimensiones, cada una con una escala de 1 a 4 (4 = mejor, 1 = peor):

- **Fidelidad del significado:** ¿la traducción conserva el significado del segmento respecto de la referencia?
- **Naturalidad / Fluidez:** ¿la traducción suena natural y es gramaticalmente correcta en español, más allá de su fidelidad al original?
- **Preservación de elementos clave:** ¿se conservan nombres propios, lugares, números, fechas, cantidades y términos culturales específicos del qom?

Ajuste y anotación. Primero anotamos el dataset B con esta guía, que en un principio solo tenía las tres dimensiones. Al hacerlo notamos que, para poder comparar después con las etiquetas (Correcta, Incorrecta, Parcialmente correcta) ya asignadas al dataset A, nos faltaba una categoría equivalente. Por eso ajustamos la guía agregando una *etiqueta global* de tres categorías derivada de las tres dimensiones, según la siguiente regla:

- **Incorrecta:** si alguna dimensión vale 1, o bien si Fidelidad vale 2.
- **Correcta:** si las tres dimensiones valen 4.
- **Parcialmente correcta:** cualquier otro caso (hay algún 3, o algún 2 que no sea de Fidelidad).

Le dimos mayor prioridad a la Fidelidad puesto que un error de significado es más grave que uno de naturalidad: un segmento con Fidelidad baja se penaliza aunque las demás dimensiones sean altas. Con esta versión final re-anotamos el dataset A; la etiqueta global del dataset B se obtuvo aplicando la misma regla a las dimensiones ya puntuadas.

2.4 Métricas seleccionadas

Para evaluar el sistema de MT sobre el dataset C usamos dos métricas: **BLEU** y **BERTScore**. Las dos comparan la traducción automática con la de referencia, pero de forma distinta: BLEU mira si coinciden las palabras y BERTScore mira si coinciden los significados. A continuación, explicamos cada una:

BLEU. BLEU (Papineni et al., 2002) cuenta cuántas palabras y grupos de palabras (de 1 a 4) aparecen tanto en la traducción automática como en la de referencia. Cuantas más coincidan, más alto es el puntaje (de 0 a 100). Además, baja la nota si la traducción es demasiado corta. La elegimos porque es la métrica más usada en traducción automática, es fácil y rápida de calcular y no necesita modelos entrenados. La calculamos con sacreBLEU (Post, 2018) (tokenizador 13a).

BERTScore. BERTScore (Zhang et al., 2020) no busca palabras idénticas, sino palabras que significan lo mismo. Para eso usa un modelo de lenguaje (tipo BERT) que convierte cada palabra en un vector y compara qué tan parecidos son los de la traducción y los de la referencia. Así reconoce sinónimos y reformulaciones que BLEU pasa por alto, por lo que la complementa. Como traducimos qom→español, el texto que evaluamos está en español, así que usamos el modelo multilingüe bert-base-multilingual-cased (lang=es) con reescalado respecto de la línea base oficial, que hace los valores más interpretables, y se promedia a nivel de oración (no tiene variante de corpus).

Ventajas y limitaciones para una lengua de bajos recursos. Algo importante de nuestro trabajo es que la traducción va de qom a español, así que las métricas trabajan sobre el español, no sobre el qom. Esto es una ventaja frente al caso contrario que estudia AmericasNLP (De Gibert et al., 2025), donde el texto a evaluar está en la lengua indígena y faltan modelos y herramientas. Aún así, hay límites: (i) las métricas no miran el qom original, solo comparan el español generado con una única referencia, así que no se dan cuenta si se perdió o cambió el sentido del texto de partida; una traducción que suena bien pero dice otra cosa puede tener el mismo puntaje. (ii) BLEU castiga cuando se usan otras palabras válidas (sinónimos, otro orden, otra conjugación); por eso en lenguas de bajos recursos se suele preferir chrF (Popović,

2015). BERTScore tolera mejor esto, pero depende de qué tan bueno sea el modelo que usa. (iii) el dataset de evaluación es chico y tiene una sola referencia, así que los puntajes son poco estables. Por eso tomamos estas métricas como una pista aproximada y las comparamos con la evaluación humana.

2.5 Data Statements

Documentamos quiénes hicimos la anotación, ya que nuestro perfil influye en los juicios de calidad. Somos tres estudiantes argentinos de Ciencia de Datos, de alrededor de 22 años, hablantes nativos de español y sin conocimiento de qom, con poca experiencia previa en anotación. Los tres anotamos todos los datasets. Una consecuencia directa es que no pudimos juzgar la fidelidad contra el qom de origen, sino solo contra la traducción de referencia en español.

El criterio usado para anotar el dataset C fue elaborado por el **Grupo 5** (véase el Apéndice C, que enlaza su criterio de anotación junto con sus *data statements*).

2.6 Detalles técnicos e implementación del IAA

Para medir el acuerdo entre anotadores usamos el Alpha de Krippendorff (Krippendorff, 2018), apropiado cuando hay varios anotadores y una escala ordinal, mediante la librería `krippendorff` de Python. Lo calculamos sobre la etiqueta global de tres categorías y sobre cada dimensión de la guía, además del dataset C con la escala del Grupo 5. Además, reportamos cuántos segmentos tuvieron acuerdo total (3/3), acuerdo de la mayoría (2/3) o desacuerdo completo, junto con la matriz de confusión entre anotadores (se construyeron como matrices de coincidencia agregando los tres pares de anotadores de cada ítem). No unificamos las anotaciones en una sola etiqueta: las diferencias se reportan tal cual, ya que son justamente lo que nos interesa analizar.

3 Resultados

Todos los links a las anotaciones se incluyen en el Apéndice A.

3.1 Acuerdo entre anotadores

Dataset A, sin criterio definido La evaluación libre en tres niveles se trató como ordinal (Incorrecta<Parcialmente correcta<Correcta). El acuerdo fue bueno ($\alpha = 0,79$): 10 de 15 segmentos con acuerdo unánime (67%) y 5 con acuerdo

Conjunto (global)	Escala	α	3/3	2/3	0/3
A sin guía	ordinal	0,79	67%	33%	0%
A con guía	ordinal	1,00	100%	0%	0%
B con guía	ordinal	0,84	80%	20%	0%
C – Precisión	ordinal	0,93	53%	47%	0%
C – Fluidez	ordinal	0,73	60%	27%	13%

Tabla 1: IAA (Alpha de Krippendorff) y proporciones de acuerdo con $N = 15$ en todos los casos. En C, α se computa sobre los puntajes crudos 0–20 y las proporciones sobre los valores redondeados a los rangos.

mayoritario (33%), sin casos de desacuerdo total (Tabla 1).

El desacuerdo casi siempre ocurre entre niveles adyacentes: en la matriz de confusión (Fig. 1a) todos los pares en desacuerdo son del tipo Incorrecta/Parcialmente correcta o Parcialmente correcta/Correcta.

Dataset A, con criterio propio Al volver a anotar A con el criterio propio, el acuerdo fue total ($\alpha = 1,00$ ordinal en la etiqueta global, unanimidad en los 15 segmentos). Por dimensión (escala ordinal 1–4; Tabla 2), el acuerdo fue alto en Fidelidad ($\alpha = 0,96$) y moderado en Naturalidad (0,72) y Preservación (0,73). Respecto de la versión sin guía, α aumenta de 0,79 a 1,00.

Dataset B, con criterio propio Sobre un conjunto no empleado en el diseño de la guía, el acuerdo global fue alto ($\alpha = 0,84$; 12/15 unánimes). Por dimensión, Fidelidad mantiene un acuerdo elevado (0,89), mientras que Naturalidad y Preservación bajan (0,31 y 0,52).

El bajo valor de Naturalidad coincide con un acuerdo observado alto (13/15 unánimes) pero escasa varianza (puntajes casi siempre 3–4): al ser elevado el acuerdo esperado por azar, α baja.

Dataset C, con criterio externo La Precisión muestra acuerdo alto ($\alpha = 0,93$) y la Fluidez, moderado ($\alpha = 0,73$). Para las proporciones de acuerdo y la confusión redondeamos cada puntaje al rango más cercano $\{0, 5, 10, 15, 20\}$: en Precisión, 8/15 unánimes y 7/15 mayoritarios. En Fluidez, 9/15 unánimes, 4 mayoritarios y 2 en desacuerdo total.

3.2 Métricas automáticas

Calculamos BLEU y BERTScore, comparando la salida automática contra la referencia en español sobre los 120 segmentos únicos del conjunto C (15 compartidos más 35 por anotador). BLEU se

Dimensión	A (con guía)		B	
	α	3/3	α	3/3
Fidelidad	0,96	87%	0,89	67%
Naturalidad	0,72	60%	0,31	87%
Preservación	0,73	73%	0,52	47%

Tabla 2: IAA por dimensión de la guía propia (escala ordinal 1–4, $N = 15$).

Métrica	Nivel	Valor
BLEU	corpus	28,8
BLEU	oración (media)	45,3
BLEU	oración (mediana)	37,7
BERTScore F1	oración (media)	0,656
BERTScore Precisión	oración (media)	0,681
BERTScore Recall	oración (media)	0,634

Tabla 3: Métricas automáticas sobre el conjunto C ($N = 120$), con el nivel de agregación de cada una. sacreBLEU 2.6.0 (13a; smoothing exp a nivel de oración); BERTScore con el modelo multilingüe (bert-base-multilingual-cased) y reescalado oficial respecto de la línea base (Zhang et al., 2020).

computa a nivel de corpus y, para la correlación, a nivel de oración (con smoothing exponencial), mientras que BERTScore se reporta como media de los puntajes por oración. La Tabla 3 indica el nivel de agregación de cada métrica.

Sin reescalado, los valores absolutos de BERTScore no son directamente interpretables: por la similitud de base entre oraciones en español, incluso pares no relacionados reciben puntajes altos. El reescalado oficial respecto de la línea base (Zhang et al., 2020) corrige esto ubicando esos pares cerca de 0, y deja el F1 en 0,656.

El valor de BLEU debe leerse en el contexto de bajos recursos: como referencia de literatura, en el shared task AmericasNLP 2025 (De Gibert et al., 2025) el mejor sistema de traducción hacia el español promedia BLEU $\approx 7,2$ sobre 13 lenguas indígenas (allí la métrica principal es chrF++). El qom no integra ese conjunto y los segmentos de C son breves, por lo que la comparación es solo orientativa: el BLEU de 28,8 refleja en buena medida esa diferencia de tarea (lengua, dirección y longitud de los segmentos) más que necesariamente un sistema superior.

3.3 Comparación humana vs. automática

Para cada segmento de C tomamos como ground truth el promedio de los anotadores (tres en los segmentos compartidos, uno en el resto) y lo correlacionamos con cada métrica mediante el coeficiente

Matrices de confusión (coincidencia por pares de anotadores)




Figura 1: Matrices de confusión por pares de anotadores. Cada ítem aporta sus 3 pares, contabilizados de forma simétrica (un par que coincide suma 2 en la diagonal). (a) Conjunto A sin guía, etiqueta global; (b) y (c) Precisión y Fluidez del conjunto C, redondeadas a los rangos 0–20.

Métricas automáticas vs. juicio humano de Precisión (conjunto C, N=120)




Figura 2: Métricas automáticas frente al juicio humano de Precisión (conjunto C, $N = 120$). La recta es el ajuste lineal y r es el coeficiente de Pearson.

Métrica	Precisión	Fluidez	Global
BLEU (oración)	0,69	0,31	0,62
BERTScore F1 (oración)	0,78	0,45	0,74

Tabla 4: Correlación de Pearson (r) entre cada métrica (a nivel de oración) y el juicio humano ($N = 120$).

de Pearson (r). Ambas métricas se correlacionan de forma significativa con el juicio humano y, en todos los casos, más con Precisión que con Fluidez (Tabla 4, Fig. 2).

BERTScore supera a BLEU frente a las tres variables humanas. El patrón se mantiene al restringir el análisis a los 15 segmentos compartidos (promediados sobre tres anotadores): BERTScore–Precisión $r = 0,82$ y BLEU–Precisión $r = 0,61$, mientras que la correlación con Fluidez no resulta significativa.

4 Discusion

Uno de los resultados más claros del trabajo es que contar con una guía ayuda a anotar de manera más consistente. En el conjunto A, el acuerdo pasa de $\alpha = 0,79$ sin criterio a $\alpha = 1,00$ con criterio propio. Sin embargo, ese aumento hay que interpretarlo con cautela. El conjunto A no fue solamente un conjunto de evaluación: también fue el material con el que fuimos detectando ambigüedades y afinando la guía. En ese sentido, parte del mejor acuerdo puede deberse a que el criterio quedó, al menos en alguna medida, ajustado a ese mismo conjunto. Por eso, el acuerdo perfecto sobre A no demuestra por sí solo que la guía sea igualmente robusta en datos nuevos.

Creemos que el conjunto B da una imagen más realista de la calidad general del criterio. Allí el acuerdo global sigue siendo alto ($\alpha = 0,84$), pero

ya no perfecto, y aparecen con más claridad las dimensiones donde la guía deja margen a la interpretación, sobre todo Naturalidad y Preservación. Esto sugiere que la guía fue útil para ordenar la tarea, pero no elimina del todo la subjetividad, especialmente cuando la traducción es entendible pero suena poco natural, o cuando hay que decidir si cierto elemento cultural o léxico importante realmente fue preservado.

Las principales dificultades durante la anotación estuvieron bastante alineadas con los casos de desacuerdo. En la evaluación inicial de A, muchos desacuerdos no parecen surgir de errores completamente distintos, sino de la duda entre dos categorías vecinas. Un problema frecuente fue decidir cuánto penalizar traducciones que preservaban parte del contenido pero perdían matices importantes, agregaban algo no presente en la referencia o resultaban poco naturales en español. La guía propia ayudó a reducir esa ambigüedad porque separó la evaluación en dimensiones y le dio prioridad explícita a la Fidelidad.

Al mirar las métricas automáticas, los resultados son razonables pero también muestran límites claros. Tanto BLEU como BERTScore correlacionan con el juicio humano, y BERTScore lo hace mejor, en particular con Precisión. Esto era esperable porque BERTScore tolera mejor reformulaciones y sinónimos. Aun así, ninguna de las métricas reemplaza una evaluación humana cuidada. Las dos comparan la salida del sistema con una referencia en español y, por lo tanto, capturan mejor la cercanía con esa referencia que problemas más finos del qom original. En otras palabras, una traducción puede sonar razonable e incluso parecer cercana a la referencia, pero igual estar omitiendo o alterando parte del significado del segmento fuente.

Esto se conecta con una limitación importante de nuestro trabajo: quienes anotamos somos hablantes de español sin conocimiento de qom. En la práctica, no evaluamos directamente la traducción qom→español, sino la cercanía entre la salida automática y una traducción de referencia al español. Eso alcanza para detectar muchos problemas, pero no todos. Una persona monolingüe en español puede identificar falta de fluidez, rarezas gramaticales, partes omitidas frente a la referencia y algunos errores semánticos evidentes, pero no puede asegurar por sí sola si el contenido del qom fue realmente preservado. Para una evaluación más fuerte haría falta, idealmente, participación de hablantes de qom o de personas con formación lingüística

específica sobre la lengua, además de más de una referencia cuando sea posible.

También hay que ser prudentes al interpretar la comparación entre evaluación humana y automática en el conjunto C. Aunque las correlaciones son significativas, el conjunto sigue siendo chico y en la mayor parte de los segmentos el juicio humano proviene de un solo anotador. Eso introduce ruido y hace que las conclusiones sean más exploratorias que definitivas. Aun así, el patrón general parece estable: las métricas reflejan mejor la dimensión de Precisión que la de Fluidez, lo cual tiene sentido dado que ambas se apoyan en la similitud con la referencia y no en un juicio independiente de naturalidad.

5 Conclusiones

Evaluamos la traducción automática qom→español del corpus QomL'aqtaqa combinando anotación humana, acuerdo entre anotadores y métricas automáticas. El resultado principal es que explicitar criterios vuelve la tarea más consistente: una guía breve, con pocas dimensiones y reglas claras, llevó el acuerdo del conjunto A de $\alpha = 0,79$ a 1,00 y se sostuvo alto en datos nuevos ($\alpha = 0,84$ en el conjunto B). Aun así, no todas las dimensiones son igual de evaluables: Fidelidad fue la más estable, mientras que Naturalidad y Preservación siguieron dependiendo de la interpretación de cada anotador. En cuanto a las métricas, BLEU y BERTScore correlacionaron con el juicio humano (sobre todo con Precisión, y BERTScore por encima de BLEU), pero ninguna reemplaza la evaluación humana.

La limitación de fondo es que anotamos sin conocimiento de qom, de modo que juzgamos la cercanía con una referencia en español más que la fidelidad al original. Por eso entendemos este trabajo como una primera aproximación ordenada al problema, no como una evaluación definitiva. Las líneas naturales de continuación son probar la guía en un conjunto completamente nuevo, sumar hablantes o especialistas en qom, documentar ejemplos típicos de error por categoría y contrastar BLEU y BERTScore con métricas pensadas para lenguas de bajos recursos, como chrF o COMET.

Referencias

Emily M. Bender and Batya Friedman. 2018. Data statements for natural language processing: Toward mitigating system bias and enabling better science.

Transactions of the Association for Computational Linguistics, 6:587–604.

Viviana Cotik, A. Korablev, P. Cúneo, and P. Laciana. 2026. QomL’aqtaqa: A qom–spanish parallel corpus for natural language processing with machine translation evaluation. In *Proceedings of the Sixth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*. To appear.

Ona De Gibert, Robert Pugh, Ali Marashian, Raúl Vázquez, Abteen Ebrahimi, and 1 others. 2025. Findings of the AmericasNLP 2025 shared tasks on machine translation, creation of educational material, and translation metrics for indigenous languages of the americas. In *Proceedings of the Fifth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, pages 134–152.

Abteen Ebrahimi, Manuel Mager, Shruti Rijhwani, Enora Rice, Arturo Oncevay, and 1 others. 2023. Findings of the AmericasNLP 2023 shared task on machine translation into indigenous languages. In *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, pages 206–219.

Yvette Graham, Timothy Baldwin, and Nitika Mathur. 2013. Continuous measurement scales in human evaluation of machine translation. In *Proceedings of WMT 2013*.

Daniel Jurafsky and James H. Martin. 2026. Machine translation. Speech and Language Processing, 3rd ed. draft, Chapter 12. <https://web.stanford.edu/~jurafsky/slp3/12.pdf>.

Klaus Krippendorff. 2018. *Content Analysis: An Introduction to Its Methodology*, 4th edition. SAGE Publications.

Arle Lommel, Aljoscha Burchardt, and Hans Uszkor-eit. 2014. Multidimensional quality metrics (MQM): A framework for declaring and describing translation quality metrics. In *Proceedings of the EACL Workshop on Translation Evaluation*.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 311–318.

Maja Popović. 2015. chrF: character n-gram f-score for automatic MT evaluation. In *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT)*, pages 392–395.

Matt Post. 2018. A call for clarity in reporting BLEU scores. In *Proceedings of the Third Conference on Machine Translation (WMT)*, pages 186–191.

Ricardo Rei, Craig Stewart, Ana C. Farinha, and Alon Lavie. 2020. COMET: A neural framework for MT evaluation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 2685–2702.

B. Ticona, F. M. Carranza, and V. Cotik. 2025. Indigenous languages spoken in argentina: a survey of NLP and speech resources. In *Proceedings of the 31st International Conference on Computational Linguistics*, pages 8449–8461.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2020. BERTScore: Evaluating text generation with BERT. In *Proceedings of the 8th International Conference on Learning Representations (ICLR)*.

A Anotaciones (enlaces)

Las planillas con las anotaciones completas están disponibles en los siguientes enlaces:

- **Conjunto A** (sin criterio): [enlace](#).
- **Conjunto A** (con criterio propio): [enlace](#).
- **Conjunto B** (criterio propio): [enlace](#).
- **Conjunto C** (criterio externo): [enlace](#).

B Criterio de anotación propio

El criterio de anotación que elaboramos para nuestras anotaciones está disponible en el siguiente [enlace](#).

C Criterio de anotación del Grupo 5

El criterio de anotación que utilizamos para el conjunto C fue elaborado por el **Grupo 5**, e incluye sus *data statements*. El documento completo está disponible en el siguiente [enlace](#).